

1조 AI-OCR 활용 프로젝트 성능 평가 최종 보고서

- 프로젝트명: SafeSign
- 팀명: 1조
- 작성일: 2025년 7월 4일
- 핵심 결론: 모델 5 (모델 3 + 데이터 추가 파인튜닝)가 단순 문자 인식률(CER)은 아쉽지만, 다양한 형태의 계약 문서에서 핵심 정보를 가장 정확하고 안정적으로 추출하여 본 프로젝트의 목표 시스템에 가장 적합한 모델로 최종 선정됨.

1. 분석 개요

1.1. 프로젝트 개요 및 평가 목적

본 프로젝트는 '생성 AI 응용 서비스 개발자 양성과정 3회차' 세미 프로젝트의 일환으로, 부동산 계약 문서의 내용을 자동으로 분석하고 핵심 정보를 요약하여 이용자에게 잠재적 위험을 알려주는 AI 응용 서비스를 개발하는 것을 목표로 합니다.

이미지 인식의 전체 워크플로우는 아래와 같이 3단계의 파이프라인으로 구성되며, OCR은 이 시스템을 구성하는 핵심 부품 중 하나입니다.

- 이미지 전처리: 입력된 문서 이미지의 노이즈를 제거하고 명암을 보정하여 OCR 인식률을 높입니다.
- OCR 인식: 전처리된 이미지에서 텍스트를 추출합니다.
- Gemini 후처리 및 요약: 추출된 텍스트를 Gemini AI 모델에 전달하여, 최종적으로 구조화된 형식의 요약문을 생성합니다.

이 워크플로우에서 Gemini 후처리는 문맥에 기반한 오타자나 어색한 문장을 유추하여 교정할 수 있지만, 잘못 인식된 숫자, 주소, 이름과 같은 사실(Fact) 정보는 수정할 수 없습니다. 이러한 정보 오류는 사용자가 직접 수정해야만 하므로, 전체 시스템의 신뢰도와 사용성을 저하하는 가장 큰 원인이 됩니다.

따라서 본 성능 평가는 위 워크플로우에 가장 최적화된, 즉 수정이 불가능한 핵심 정보(숫자, 주소, 이름 등)의 오류율을 최소화하는 최적의 OCR 모델을 선정하는 데 그 목적이 있습니다.

1.2. 모델 개발 및 데이터 구축 과정

성능 평가를 위해 각기 다른 전략으로 7개의 모델을 준비했습니다. 특히 자체 파인튜닝 모델(2~6번)의 데이터 구축 과정은 다음과 같습니다.

모델 번호	모델명	데이터 구축 및 파인튜닝 전략
-------	-----	------------------

1	기본 OCR	EasyOCR의 korean_g2 사전 학습 모델을 그대로 사용 (Baseline)
2	실패한 파인튜닝	【초기 모델】 AI-Hub의 '다양한 형태의 한글 문자 OCR' 데이터셋과 QMNIST 필기체 숫자 데이터 약 40만 개를 2:2:3:3 비율로 구성하여 korean_g2 모델을 파인튜닝.
3	다양한 데이터셋 파인튜닝	【모델 2 개선】 위와 동일한 데이터셋 구성으로, 학습 과정의 문제를 해결하고 정상적으로 파인튜닝 완료.
4	계약서 소규모 파인튜닝	【모델 3 특화】 모델 3에 실제 계약서 및 등기부등본 샘플을 라벨링한 소규모 데이터셋을 추가로 파인튜닝하여 도메인 특화 시도.
5	계약서 데이터 추가 파인튜닝	【모델 4 확장】 모델 4의 접근법을 확장하여, 더 많은 양의 계약서/등기부등본 데이터를 추가하여 모델 3을 파인튜닝. (주요 분석 모델)
6	생성 이미지 파인튜닝	이미지 생성 스크립트를 통해 주소, 이름, 숫자 등 계약서 관련 텍스트 이미지 70만 개(인쇄체/필기체 5:5)를 가상으로 생성하여 korean_g2 모델을 파인튜닝.
7	외부 파인튜닝 모델	공공행정문서를 학습시킨 외부의 korean_g2 파인튜닝 모델을 사용하여 성능 비교.

1.3. 평가 방법론

본 평가는 두 가지 핵심 지표를 통해 모델의 성능을 다각적으로 측정합니다.

1. Cleaned CER (문자 오류율):

- 각 모델이 추출한 원본 텍스트(Raw Text)를 Gemini AI를 통해 1차적으로 교정한 후, 이 교정된 텍스트와 정답 텍스트 간의 문자 단위 오류율을 측정합니다. 이는

AI 후처리를 거친 후에도 남아있는 순수 **OCR** 오류를 평가하는 지표입니다.

2. 요약 정확도 (핵심 지표):

- 프로젝트의 최종 목표인 '정확한 요약문 생성' 능력을 직접 측정하기 위해, 프로젝트에 실제로 적용되는 **gemini** 정규화 프롬프트의 일부를 넣어 필요한 정보가 어느정도 정답을 도출하는지 확인합니다.
 - 기준 정답(**Golden Set**) 생성: 완벽한 원본 텍스트(answer.txt)를 지정된 프롬프트에 입력하여, Gemini AI가 생성할 수 있는 가장 이상적인 '정답 요약본'을 만듭니다.
 - 모델별 요약본 생성: 7개 OCR 모델이 각각 추출한 텍스트를 동일한 프롬프트에 입력하여, 모델별로 7개의 요약 결과물을 생성합니다.
 - 정확도 채점: 각 모델이 생성한 요약본을 '기준 정답 요약본'과 항목별로 비교하여, 문자열 유사도(%)를 계산하고 평균을 내어 '요약 정확도'를 산출합니다.

2. 종합 성능 평가 결과 (샘플 10종 평균)

2.1. 종합 순위

종합 순위	모델 번호	모델명	Cleaned CER (낮을수록 좋음)	요약 정확도 (%) (높을수록 좋음)
 1	5	모델 3 + 데이터 추가 파인튜닝	0.2033	82.42%
2	7	외부 korean_g2 파인튜닝 모델	0.1588	80.67%
3	1	기본 OCR (korean_g2.pth)	0.1731	80.33%
4	4	모델 3 + 계약서/등기 데이터 추가 파인튜닝	0.2033	78.00%
5	3	다양한 데이터셋 파인튜닝	0.2328	69.25%
6	6	korean_g2 + 생성 이미지 파인튜닝	0.4533	54.92%
7	2	실패한 파인튜닝 모델	0.8405	7.42%

2.2. 평가 점수에 대한 보충 설명

상위권 모델의 '요약 정확도' 점수가 **80%** 초반대로 보이는 것은 자동화된 채점 방식의 한계 때문입니다. 예를 들어, 원본 계약서에 명도일이나 임대차 기간 정보가 비어있는 경우가 있습니다. 이 경우, AI가 해당 항목을 정확하게 비워두는 것이 정답이지만, 현재의 채점 알고리즘은 이처럼 '의도된 빈칸'을 낮은 점수로 처리하는 경향이 있습니다.

이러한 모든 예외 케이스를 반영하여 채점 알고리즘을 완벽하게 구현하는 것은 현실적으로 어렵습니다.

수치상으로 표현된 **82.42%**라는 점수보다, 실제 사용자가 느끼는 체감 정확도는 훨씬 높다고 할 수 있습니다.

2.3. 결과 요약


분석 결과, 초기 문자 인식률(**CER**)과 최종 정보 추출 정확도가 반드시 비례하지 않음을 명확히 확인했습니다.

모델 **5**는 CER 지표 자체는 모델 **7, 1**보다 다소 높았으나, 실제 계약서의 핵심 정보를 추출하고 구조를 이해하는 능력에서는 다른 모든 모델을 앞서며 ****가장 높은 '요약 정확도' 점수(평균 82.42%)***를 기록했습니다.

이는 단순 텍스트 정확도를 넘어, 모델이 문서의 '맥락'과 '핵심 가치'를 얼마나 잘 이해하는지가 실제 활용 가치를 결정한다는 점을 시사합니다. 즉, 사소한 오타를 일부 포함하더라도 "보증금", "계약일"과 같은 핵심 정보를 틀리지 않는 능력이 더 중요합니다.

3. 상세 분석

3.1. 문자 오류율(CER) 분석



1차 CER 평가에서는 모델 7과 1이 각각 평균 0.1588, 0.1731로 가장 낮은 오류율을 보이며 텍스트를 글자 그대로 인식하는 능력은 우수하게 나타났습니다. 모델 5는 평균 0.2033으로 중위권의 CER 수치를 기록했습니다.

3.2. 최종 요약 성능 분석

각 모델의 OCR 결과를 AI 요약 프롬프트에 직접 입력하여 최종 결과물의 품질을 평가한 결과, 순위는 역전되었습니다.

오류 사례 비교: 핵심 정보 인식의 안정성

CER이 가장 낮았던 모델 7과 모델 1은 일부 핵심 정보에서 오류를 보이는 경우가 있었습니다. 이는 단순 텍스트 인식률과 실제 정보 추출 안정성 간에 차이가 있을 수 있음을 보여줍니다.

항목	🏆 모델 5 (82.4%)	🥈 모델 7 (80.7%)	🥇 모델 1 (80.3%)
보증금	30,000,000원 (정답)	30,980,000원 (98만원 차이)	30,000,000원 (정답)
계약일	2025 (정답)	2025 (정답)	2925 (900년 차이)

위 표는 대표적인 오류 사례로, 모델 7은 보증금을, 모델 1은 계약일을 잘못 인식하는 모습을 보였습니다. 이러한 유형의 오류는 후속 Gemini 단계에서 자동으로 수정되기 어려워, 최종 결과물의 신뢰성에 영향을 줄 수 있습니다.

반면, 모델 5는 다양한 문서 샘플 전반에 걸쳐 가장 중요한 숫자와 핵심 정보를 보다 안정적으로 인식하는 경향을 보였습니다.

3.3. 주요 모델별 실패 사례 분석 (Lessons Learned)

이번 프로젝트를 통해 몇 가지 중요한 교훈을 얻을 수 있었습니다.

- **모델 2 (실패한 파인튜닝):**
 - 문제점: 파인튜닝 과정에서 학습 초기 정확도(accuracy)가 0%대에 머물렀음에도, 이것이 파인튜닝이 되지 못하고 있다는 것을 인지하지 못하고 학습을 완료했습니다. 그 결과, 모델은 문자 인식이 불가능한 수준의 결과를 출력했습니다.
 - 교훈: 파인튜닝 시에는 초기 학습 과정의 지표(Loss, Accuracy)를 모니터링하여 학습이 정상적으로 진행되고 있는지 확인해야 함을 깨달았습니다.
- **모델 6 (생성 이미지 파인튜닝):**
 - 문제점: 계약서에 자주 등장하는 숫자, 전화번호, 주민등록번호 등의 데이터를 대량(70만 개)으로 생성하여 학습시킨 결과, 모델이 과적합(Overfitting)되는 경향을 보였습니다. 이로 인해 일반적인 한글 단어조차 숫자로 오인하는(예: '가' -> '4') 문제가 발생했습니다.
 - 교훈: 데이터의 양뿐만 아니라, 일반 텍스트와 특정 패턴 데이터 간의 균형이 매우 중요함을 확인했습니다. 무조건 많은 데이터를 사용하는 것보다, 균형 잡힌 데이터셋을 구축하는 것이 모델의 일반화 성능에 더 효과적입니다.

4. 최종 결론

단순히 글자를 얼마나 똑같이 베껴 쓰는지를 평가하는 문자 오류율(CER)만으로는 계약서와 같이 정형화된 문서에서 정보 추출 성능을 올바르게 평가할 수 없습니다.

모델 5는 CER 수치 이상의 문서 이해 능력과 정보 추출 안정성을 보여주었습니다. 이는 '다양한 데이터(모델 3) -> 도메인 특화(모델 4) -> 데이터 확장(모델 5)'으로 이어지는 점진적인 파인튜닝 전략이 모델의 특정 상황에서의 성능을 향상시켜, 어떤 정보가 더 중요한지를 판단하고 안정적으로 처리하는 능력을 길러주었음을 의미합니다.

따라서, 프로젝트의 목표인 '신뢰도 높은 자동 요약 시스템' 개발 성공률을 극대화하기 위해, '모델 5'를 최종 OCR 모델로 선정하여 프로젝트의 핵심 엔진으로 확정하였습니다.